

Önmagával és a gold standard címkével részben vagy egészben megegyező válaszpárok eloszlása




Figure 1: Három modell konzisztens, pontos és bizonytalan párjainak száma 100 kérdéspáron. A konzisztensen pontos párok száma a konzisztens és pontos párok matematikai metszete.

Az ábrán látható, hogy meglepő módon a legkisebb modell, a Qwen 0.5B érte el a legjobb mutatókat a konzisztens és konzisztensen pontos párok számában is. Pontosságban viszont alulmaradt a Qwen 1.5B-hez és a Gemma 2B-hez képest is, melyek egyformán 76 pontos párt adtak. A Word-in-Context adathalmaz minden metszetében egyenlő arányban szerepelnek “True” (igaz) és “False” (hamis) címkék, így az alapként használt `test` metszetben is. A megindexelt válaszokhoz tartozó gold standardbeli címkék eloszlásának szummázásával kimutattam, hogy a választott 100 kérdéspárhoz tartozó címke pont egy elég torz, 35 “True” és 65 “False” címkét tartalmazó mintapár volt. A Qwen 0.5B modellről pedig egyértelműen megállapítható volt, hogy a “nem” választ preferálja a döntéseiben. Ez két tényező összeállása lehet a fő oka, hogy a Qwen 0.5B rendkívül jó konzisztens pontosságot ért el, ám feltételezhető, hogy egyenletes eloszlású címkék esetén romlana a teljesítménye, hiszen a pontos párok arányában viszont enyhén elmaradt a nagyobb paraméterszámú modellektől. Márpedig a pontos párok aránya jól mutatja az általános érvelési képességet, hiszen itt nincs figyelembe véve a konzisztencia, csak az, hogy a modell helyes választ adott-e a gold standarddal összevetve.

Gold standarddal megegyező egyenkénti válaszok száma modellenként




Figure 2: Három modell pontos egyenkénti válaszainak (gold standard címkével való egyezések számának) összehasonlítása ugyanezen a 200 véletlenszerű kérdésen.

Gold standarddal egyező válaszok száma modellenként




Figure 3: A három modell “Yes” és “No” válaszainak darabszáma ugyanerre a 200 egyenkénti kérdésre összevetve a gold standard címkék arányával. Mivel egy kérdésre az egyenes és a fordított válasznak is ugyanaz a gold címkéje, így az ábrához a “True” és “False” címkék darabszámát, amelyek megfeleltethetők a model által adott “igen” és “nem” válaszoknak, duplán kell számolni.